

MiniGPT4-Finetuning

项目展示

夏子渊 金裕涵 林滨 程韬 潘越

NLP Group 33

Jun. 22nd, 2025

Outline

1. Project Introduction

2. Technical Details

3. Experiment Results

Outline

1. Project Introduction

2. Technical Details

3. Experiment Results

1. Project Introduction

MiniGPT-4 通过结合视觉编码器与 Vicuna 语言模型，实现了图像到文本的高质量对齐。为了进一步提升其在 Image Captioning 任务上的理解与表现，我们开展了面向 Flickr30k 数据集的指令微调。

1. Project Introduction

实验环境:

- 操作系统: Ubuntu 18.04 LTS
- 显卡: NVIDIA GeForce RTX 3090 \times 7
- Python: 3.10.13
- CUDA: 11.7
- PyTorch: 2.0.1

Outline

1. Project Introduction

2. Technical Details

3. Experiment Results

2.1 理论知识

2.1.1 指令微调

指令微调 (Instruction Tuning) 是指在大规模预训练语言模型的基础上, 利用带有明确指令 (instruction) 的数据对模型进行再训练, 使其能够更好地理解和执行各种自然语言指令。其核心思想是通过多样化的指令-响应对, 提升模型的泛化能力和任务适应能力。

具体来说, 假设我们有一个预训练模型 f_θ , 输入为图像 I 和文本指令 x , 输出为文本 y 。指令微调的目标是最小化如下损失函数:

$$\mathcal{L}(\theta) = \mathbb{E}_{(I,x,y) \sim \mathcal{D}} [-\log P_\theta(y|I, x)]$$

其中 \mathcal{D} 表示带有指令的训练数据集。

2.1 理论知识

例如，给定一张图片 I 及指令 x ：

- 指令 x ：“请详细描述这张图片的内容。”
- 期望输出 y ：“一只小狗在草地上奔跑，背景有蓝天和白云。”

通过指令微调，模型不仅学习到图片与文本的对应关系，还能理解“详细描述”这类指令的语义，从而在遇到不同指令时做出相应的生成。

2.1 理论知识

2.1.2 视觉语言模型

视觉语言模型（Vision-Language Model, VLM）是一类能够同时处理图像和文本信息的深度学习模型，其核心思想是通过视觉编码器（如 CLIP、ViT 等）将图像提取为 image token，然后通过投影层将视觉特征映射到与文本 token 相同的向量空间，最终将图像和文本 token 拼接输入到统一的 Transformer 架构中实现联合建模，从而能够理解图片内容并根据文本指令生成相应描述，完成图像到文本的生成任务。

2.2 技术细节

2.2.1 评估指标

BLEU: 机器翻译评估指标，基于 n-gram 重叠程度，分数 0-1

- 计算 n-gram 精确率，使用简短惩罚因子
- 支持多个参考文本，对词序敏感

CIDEr: 图像描述专用评估指标，分数 0-10

- 使用 TF-IDF 加权强调重要词汇
- 考虑 n-gram 共识程度，对罕见准确描述给予更高权重

ROUGE-L: 基于最长公共子序列的评估指标，分数 0-1

- 不要求严格连续匹配，考虑词序信息
- 计算召回率和精确率，对句子结构敏感

2.2 技术细节

2.2.2 转换数据集

我们使用 `prepare_flickr30k.py` 脚本将 Flickr30k 数据集转换为适合指令微调的格式。该脚本读取原始的 `flickr_annotations_30k.csv` 文件，并生成一个 JSON 文件。对于每一个样本，我们将其 5 个参考描述（caption 列表）用空格连接起来，并和其对应的图像 ID 一起存储在 JSON 文件中。

2.2.3 定义测评指标

我们使用上述 BLEU、CIDEr 和 ROUGE-L 等指标评估模型性能。

在自定义的 `eval_scripts/eval_flickr30k.py` 中，我们利用 COCO API 实现了上述评估指标的计算。

Outline

1. Project Introduction

2. Technical Details

3. Experiment Results

3.1 训练过程展示

使用单卡 GPU 训练线性映射层：

```
torchrun --nproc-per-node 1 train.py --cfg-path train_configs/  
minigpt4_flickr_finetune.yaml
```

3.1 训练过程展示

部分训练过程如图所示:

[illegible][illegible]

```

Running Parameters
2025-06-08 11:09:06.775 [INFO] {
  amp: true,
  distributed_backend: "nccl",
  dist_url: "tcp://",
  distributor: true,
  evaluate: false,
  log: 1,
  init_lr: 3e-05,
  lr_scheduler: "warmup",
  lr_scheduler_kwargs: {
    "warmup_epochs": 500,
    "warmup_lr": 0.0001,
    "min_lr": 1e-06,
    "min_lr_epochs": 10000,
    "min_lr_scheduler": "warmup_cosine_lr",
    "min_epochs": 5,
    "min_lr": 3e-06
  },
  num_workers: 4,
  output_dir: "output/minigpt4_finetuning/lickr30k/lickr30k_finetune",
  rank: 0,
  resume_checkpoint: null,
  seed: 42,
  task: "image_text_pretrain",
  train_splits: [
    "train"
  ],
  wandb_log: true,
  warmup_lr: 1e-06,
  warmup_steps: 200,
  weight_decay: 0.05,
  world_size: 1
}
2025-06-08 11:09:06.775 [INFO] =====
Dataset Attributes =====
2025-06-08 11:09:06.775 [INFO] =====
{"lickr30k_grouped_dataset": {
  "dataset_size": 224,
  "batch_size": 1,
  "shuffle_order": 0,
  "train_loader": {
    "amp_path": "/mnt/data4/home/zyuan/MiniGPT4-finetuning/lickr30k/lickr30k_finetune_dataset.json",
    "data_loader": "/mnt/data4/home/zyuan/MiniGPT4-finetuning/lickr30k/lickr30k_images",
    "test_processor": {
      "name": "blip_caption"
    },
    "vis_processor": {
      "train": {
        "image_size": 224,
        "name": "blip_image_train"
      }
    }
  }
}
2025-06-08 11:09:06.776 [INFO] =====

```

```
2025-06-08 11:14:38.584 [INFO] Start training
2025-06-08 11:14:42.182 [INFO] dataset_rstos not specified, datasets will be concatenated (map-style datasets) or chained (webdataset.DataPipeline).
2025-06-08 11:14:42.184 [INFO] Loaded 13814 records for train split from the dataset.
batch sizes [121]
module.module.llama_proj.weight
module.module.llama_proj.bias
2025-06-08 11:14:42.215 [INFO] number of trainable parameters: 3149824
2025-06-08 11:14:42.218 [INFO] Start training epoch 0, 500 iters per inner epoch.
```

3.1 训练过程展示

部分训练结果如图所示：

epoch0:

```
Train: data epoch: [0] [ 0/500] eta: 0:07:00 lr: 0.000001 loss: 1.0093 time: 0.0414 data: 0.0001 max mem: 12819
Train: data epoch: [0] [ 50/500] eta: 0:04:39 lr: 0.000008 loss: 2.0966 time: 0.4717 data: 0.0000 max mem: 10282
Train: data epoch: [0] [100/500] eta: 0:04:43 lr: 0.000015 loss: 1.4332 time: 0.4055 data: 0.0000 max mem: 10282
Train: data epoch: [0] [150/500] eta: 0:03:18 lr: 0.000023 loss: 1.2691 time: 0.5233 data: 0.0000 max mem: 10282
Train: data epoch: [0] [200/500] eta: 0:02:42 lr: 0.000028 loss: 1.0774 time: 0.5462 data: 0.0000 max mem: 10282
Train: data epoch: [0] [250/500] eta: 0:02:15 lr: 0.000038 loss: 2.0115 time: 0.5386 data: 0.0000 max mem: 10282
Train: data epoch: [0] [300/500] eta: 0:01:48 lr: 0.000022 loss: 1.0007 time: 0.5665 data: 0.0000 max mem: 10282
Train: data epoch: [0] [350/500] eta: 0:01:22 lr: 0.000029 loss: 2.0673 time: 0.5859 data: 0.0000 max mem: 10282
Train: data epoch: [0] [400/500] eta: 0:00:55 lr: 0.000029 loss: 2.0311 time: 0.5829 data: 0.0000 max mem: 10282
Train: data epoch: [0] [450/500] eta: 0:00:27 lr: 0.000028 loss: 1.0095 time: 0.6032 data: 0.0000 max mem: 10282
Train: data epoch: [0] [499/500] eta: 0:00:00 lr: 0.000028 loss: 1.3743 time: 0.6146 data: 0.0000 max mem: 10282
Train: data epoch: [0] Total time: 0:04:04 (0.569 s / it)
2025-06-08 11:19:22.578 [INFO] Averaged stats: lr: 0.0000 loss: 1.7329
2025-06-08 11:19:22.586 [INFO] No validation splits found.
2025-06-08 11:19:22.628 [INFO] Saving checkpoint at epoch 0 to /mnt/data4/home/ziyuan/MiniGPT4-Finetuning/minigpt4/output/minigpt4_flickr_finetune/20250608118/checkpoint_0.pth.
2025-06-08 11:19:22.796 [INFO] Start training
2025-06-08 11:19:22.836 [INFO] Start training epoch 1, 500 iters per inner epoch.
```

epoch1:

```
Train: data epoch: [1] [ 0/500] eta: 0:04:23 lr: 0.000028 loss: 1.5001 time: 0.5201 data: 0.0000 max mem: 10282
Train: data epoch: [1] [ 50/500] eta: 0:04:13 lr: 0.000028 loss: 1.0284 time: 0.5728 data: 0.0000 max mem: 10283
Train: data epoch: [1] [100/500] eta: 0:03:47 lr: 0.000027 loss: 1.0005 time: 0.5726 data: 0.0000 max mem: 10283
Train: data epoch: [1] [150/500] eta: 0:03:19 lr: 0.000027 loss: 1.0785 time: 0.5775 data: 0.0000 max mem: 10786
Train: data epoch: [1] [200/500] eta: 0:02:51 lr: 0.000026 loss: 1.5015 time: 0.6048 data: 0.0000 max mem: 10786
Train: data epoch: [1] [250/500] eta: 0:02:22 lr: 0.000026 loss: 1.4398 time: 0.5709 data: 0.0000 max mem: 10786
Train: data epoch: [1] [300/500] eta: 0:01:54 lr: 0.000025 loss: 1.0219 time: 0.5529 data: 0.0000 max mem: 10786
Train: data epoch: [1] [350/500] eta: 0:01:26 lr: 0.000025 loss: 1.4437 time: 0.5807 data: 0.0000 max mem: 10786
Train: data epoch: [1] [400/500] eta: 0:00:57 lr: 0.000024 loss: 1.7056 time: 0.5553 data: 0.0000 max mem: 10786
Train: data epoch: [1] [450/500] eta: 0:00:29 lr: 0.000024 loss: 1.4488 time: 0.5738 data: 0.0000 max mem: 10786
Train: data epoch: [1] [499/500] eta: 0:00:00 lr: 0.000023 loss: 1.1011 time: 0.5920 data: 0.0000 max mem: 10786
Train: data epoch: [1] Total time: 0:04:51 (0.502 s / it)
2025-06-08 11:24:13.980 [INFO] Averaged stats: lr: 0.0000 loss: 1.6198
2025-06-08 11:24:14.003 [INFO] No validation splits found.
2025-06-08 11:24:14.048 [INFO] Saving checkpoint at epoch 1 to /mnt/data4/home/ziyuan/MiniGPT4-Finetuning/minigpt4/output/minigpt4_flickr_finetune/20250608118/checkpoint_1.pth.
2025-06-08 11:24:14.218 [INFO] Start training
2025-06-08 11:24:14.252 [INFO] Start training epoch 2, 500 iters per inner epoch.
```

epoch2:

```
Train: data epoch: [2] [ 0/500] eta: 0:04:40 lr: 0.000023 loss: 1.7806 time: 0.5083 data: 0.0000 max mem: 10786
Train: data epoch: [2] [ 50/500] eta: 0:04:22 lr: 0.000022 loss: 1.0277 time: 0.5237 data: 0.0000 max mem: 10786
Train: data epoch: [2] [100/500] eta: 0:04:00 lr: 0.000022 loss: 1.7640 time: 0.5083 data: 0.0000 max mem: 10786
Train: data epoch: [2] [150/500] eta: 0:03:38 lr: 0.000021 loss: 1.0709 time: 0.5318 data: 0.0000 max mem: 10786
Train: data epoch: [2] [200/500] eta: 0:03:00 lr: 0.000021 loss: 1.0516 time: 0.5045 data: 0.0000 max mem: 10786
Train: data epoch: [2] [250/500] eta: 0:02:38 lr: 0.000026 loss: 1.7562 time: 0.5097 data: 0.0000 max mem: 10786
Train: data epoch: [2] [300/500] eta: 0:02:10 lr: 0.000019 loss: 1.7738 time: 0.5069 data: 0.0000 max mem: 10786
Train: data epoch: [2] [350/500] eta: 0:01:38 lr: 0.000019 loss: 1.3057 time: 0.6159 data: 0.0000 max mem: 10786
Train: data epoch: [2] [400/500] eta: 0:01:00 lr: 0.000018 loss: 1.7799 time: 0.6024 data: 0.0000 max mem: 10786
Train: data epoch: [2] [450/500] eta: 0:00:38 lr: 0.000017 loss: 1.3058 time: 0.6197 data: 0.0000 max mem: 10786
Train: data epoch: [2] [499/500] eta: 0:00:00 lr: 0.000017 loss: 1.7508 time: 0.6273 data: 0.0000 max mem: 10786
Train: data epoch: [2] Total time: 0:05:43 (0.6074 s / it)
2025-06-08 11:29:13.964 [INFO] Averaged stats: lr: 0.0000 loss: 1.6839
2025-06-08 11:29:13.944 [INFO] No validation splits found.
2025-06-08 11:29:14.007 [INFO] Saving checkpoint at epoch 2 to /mnt/data4/home/ziyuan/MiniGPT4-Finetuning/minigpt4/output/minigpt4_flickr_finetune/20250608118/checkpoint_2.pth.
2025-06-08 11:29:16.168 [INFO] Start training
2025-06-08 11:29:16.222 [INFO] Start training epoch 3, 500 iters per inner epoch.
```

epoch3:

```
Train: data epoch: [3] [ 0/500] eta: 0:04:47 lr: 0.000017 loss: 1.4256 time: 0.5756 data: 0.0000 max mem: 10786
Train: data epoch: [3] [ 50/500] eta: 0:04:24 lr: 0.000016 loss: 1.7058 time: 0.6249 data: 0.0000 max mem: 10786
Train: data epoch: [3] [100/500] eta: 0:04:11 lr: 0.000016 loss: 1.7071 time: 0.6141 data: 0.0000 max mem: 10786
Train: data epoch: [3] [150/500] eta: 0:03:41 lr: 0.000015 loss: 1.4399 time: 0.6261 data: 0.0000 max mem: 10786
Train: data epoch: [3] [200/500] eta: 0:03:10 lr: 0.000015 loss: 1.6425 time: 0.6242 data: 0.0000 max mem: 10786
Train: data epoch: [3] [250/500] eta: 0:02:39 lr: 0.000014 loss: 1.6643 time: 0.6408 data: 0.0000 max mem: 10786
Train: data epoch: [3] [300/500] eta: 0:02:07 lr: 0.000014 loss: 1.6156 time: 0.6514 data: 0.0000 max mem: 10786
Train: data epoch: [3] [350/500] eta: 0:01:36 lr: 0.000013 loss: 2.1249 time: 0.6052 data: 0.0000 max mem: 10786
Train: data epoch: [3] [400/500] eta: 0:01:04 lr: 0.000013 loss: 1.6463 time: 0.6445 data: 0.0000 max mem: 10786
Train: data epoch: [3] [450/500] eta: 0:00:32 lr: 0.000012 loss: 1.6642 time: 0.6355 data: 0.0000 max mem: 10786
Train: data epoch: [3] [499/500] eta: 0:00:00 lr: 0.000012 loss: 1.5794 time: 0.6457 data: 0.0000 max mem: 10786
Train: data epoch: [3] Total time: 0:05:23 (0.6472 s / it)
2025-06-08 11:34:43.800 [INFO] Averaged stats: lr: 0.0000 loss: 1.6886
2025-06-08 11:34:41.807 [INFO] No validation splits found.
2025-06-08 11:34:41.852 [INFO] Saving checkpoint at epoch 3 to /mnt/data4/home/ziyuan/MiniGPT4-Finetuning/minigpt4/output/minigpt4_flickr_finetune/20250608118/checkpoint_3.pth.
2025-06-08 11:34:42.011 [INFO] Start training
2025-06-08 11:34:42.054 [INFO] Start training epoch 4, 500 iters per inner epoch.
```

epoch4:

```
Train: data epoch: [4] [ 0/500] eta: 0:05:10 lr: 0.000012 loss: 1.4270 time: 0.6366 data: 0.0000 max mem: 10786
Train: data epoch: [4] [ 50/500] eta: 0:04:45 lr: 0.000012 loss: 1.3008 time: 0.6205 data: 0.0000 max mem: 10786
Train: data epoch: [4] [100/500] eta: 0:04:13 lr: 0.000011 loss: 1.7157 time: 0.6428 data: 0.0000 max mem: 10786
Train: data epoch: [4] [150/500] eta: 0:03:39 lr: 0.000011 loss: 1.5292 time: 0.6222 data: 0.0000 max mem: 10786
Train: data epoch: [4] [200/500] eta: 0:03:05 lr: 0.000011 loss: 1.6249 time: 0.5932 data: 0.0000 max mem: 10786
Train: data epoch: [4] [250/500] eta: 0:02:35 lr: 0.000010 loss: 1.6235 time: 0.5904 data: 0.0000 max mem: 10786
Train: data epoch: [4] [300/500] eta: 0:02:04 lr: 0.000010 loss: 1.9784 time: 0.6186 data: 0.0000 max mem: 10786
Train: data epoch: [4] [350/500] eta: 0:01:32 lr: 0.000010 loss: 1.6016 time: 0.6101 data: 0.0000 max mem: 10786
Train: data epoch: [4] [400/500] eta: 0:01:00 lr: 0.000010 loss: 1.0132 time: 0.5789 data: 0.0000 max mem: 10786
Train: data epoch: [4] [450/500] eta: 0:00:28 lr: 0.000010 loss: 1.4456 time: 0.5207 data: 0.0000 max mem: 10786
Train: data epoch: [4] [499/500] eta: 0:00:00 lr: 0.000010 loss: 1.0859 time: 0.5099 data: 0.0000 max mem: 10786
Train: data epoch: [4] Total time: 0:05:00 (0.000 s / it)
2025-06-08 11:39:42.115 [INFO] Averaged stats: lr: 0.0000 loss: 1.5761
2025-06-08 11:39:42.121 [INFO] No validation splits found.
2025-06-08 11:39:42.166 [INFO] Saving checkpoint at epoch 4 to /mnt/data4/home/ziyuan/MiniGPT4-Finetuning/minigpt4/output/minigpt4_flickr_finetune/20250608118/checkpoint_4.pth.
2025-06-08 11:39:42.344 [INFO] No validation splits found.
2025-06-08 11:39:42.345 [INFO] Training time: 02:25:43
```

3.2 评估结果与分析

Table 1: 模型评估结果统计

	BLEU-1	BLEU-2	BLEU-3	BLEU-4	CIDEr	ROUGE-L
pretrained	0.3175	0.2371	0.1843	0.1529	0.4361	0.5758
epoch0	0.3427	0.2723	0.2204	0.2002	0.4502	0.6101
epoch1	0.3608	0.2822	0.2503	0.2320	0.4753	0.6469
epoch2	0.3728	0.3021	0.2720	0.2456	0.4829	0.6602
epoch3	0.3878	0.3314	0.2978	0.2688	0.4907	0.6701
epoch4	0.3912	0.3375	0.3005	0.2807	0.5115	0.6803

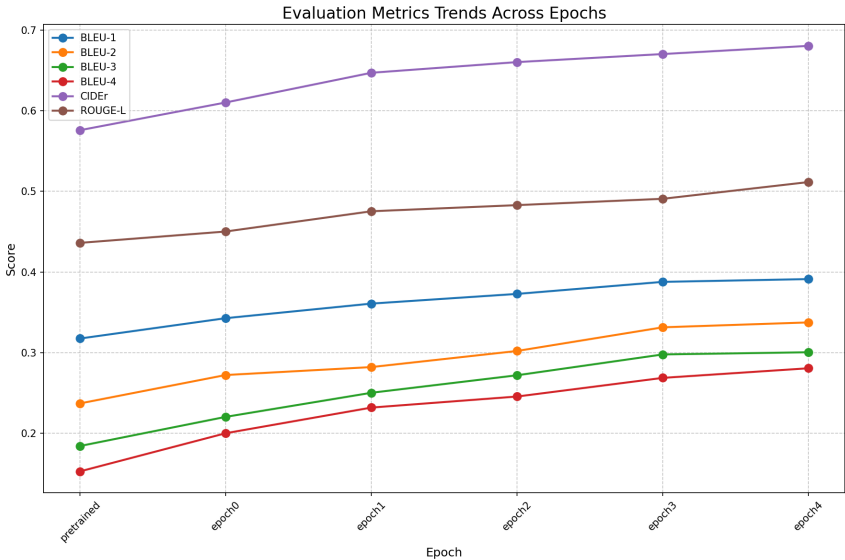


Figure 1: 模型评估结果折线图

3.2 评估结果与分析

3.2.1 模型性能持续提升

随着训练轮次 (Epoch) 的增加, 所有评价指标均呈现稳定上升趋势, 表明模型通过迭代学习有效捕捉了文本生成任务的核心规律。其中:

- 语义与连贯性优化显著: CIDEr 和 ROUGE-L 的增速远超其他指标 (详见图表斜率), 说明模型在生成内容的语义相关性、上下文连贯性上提升最为突出, 逐渐接近人类语言表达模式。
- 局部一致性稳步改进: BLEU 系列指标增长平缓但持续 (BLEU-1 至 BLEU-4 增幅约 50%-80%), 反映模型在局部词汇匹配和短语结构的准确性上逐步完善。

3.2 评估结果与分析

3.2.2 训练动态揭示关键拐点

- 早期快速收敛：pretrained 至 epoch1 阶段所有指标快速跃升，验证预训练权重提供了高质量初始化。
- 中后期差异化优化：epoch2 后 CIDEr 与 ROUGE-L 仍保持陡峭上升，而 BLEU 系列进入平缓增长期，表明模型后期更侧重于语义整体性而非局部词序精确度，符合文本生成任务的本质目标。
- 持续训练价值：截至 epoch4，各曲线仍未出现平台期，建议扩展训练轮次（如至 epoch6）以挖掘性能潜力。
- 重点优化方向：可针对性设计长依赖文本和抽象语义的增强训练模块（如注意力机制改进），进一步发挥 CIDEr 与 ROUGE-L 的优势。

3.2 评估结果与分析

3.2.3 局限性与后续工作

- 评估维度补充：需增加人工评价或 SPICE 等细粒度指标，验证模型在视觉语义对齐上的表现（若为多模态任务）。
- 泛化能力检验：当前结果基于单一数据集，需在跨领域数据上验证鲁棒性。
- 探索更大的语言模型后端。
- 优化推理速度与显存占用。

3.2 评估结果与分析

Thank you for your attention!